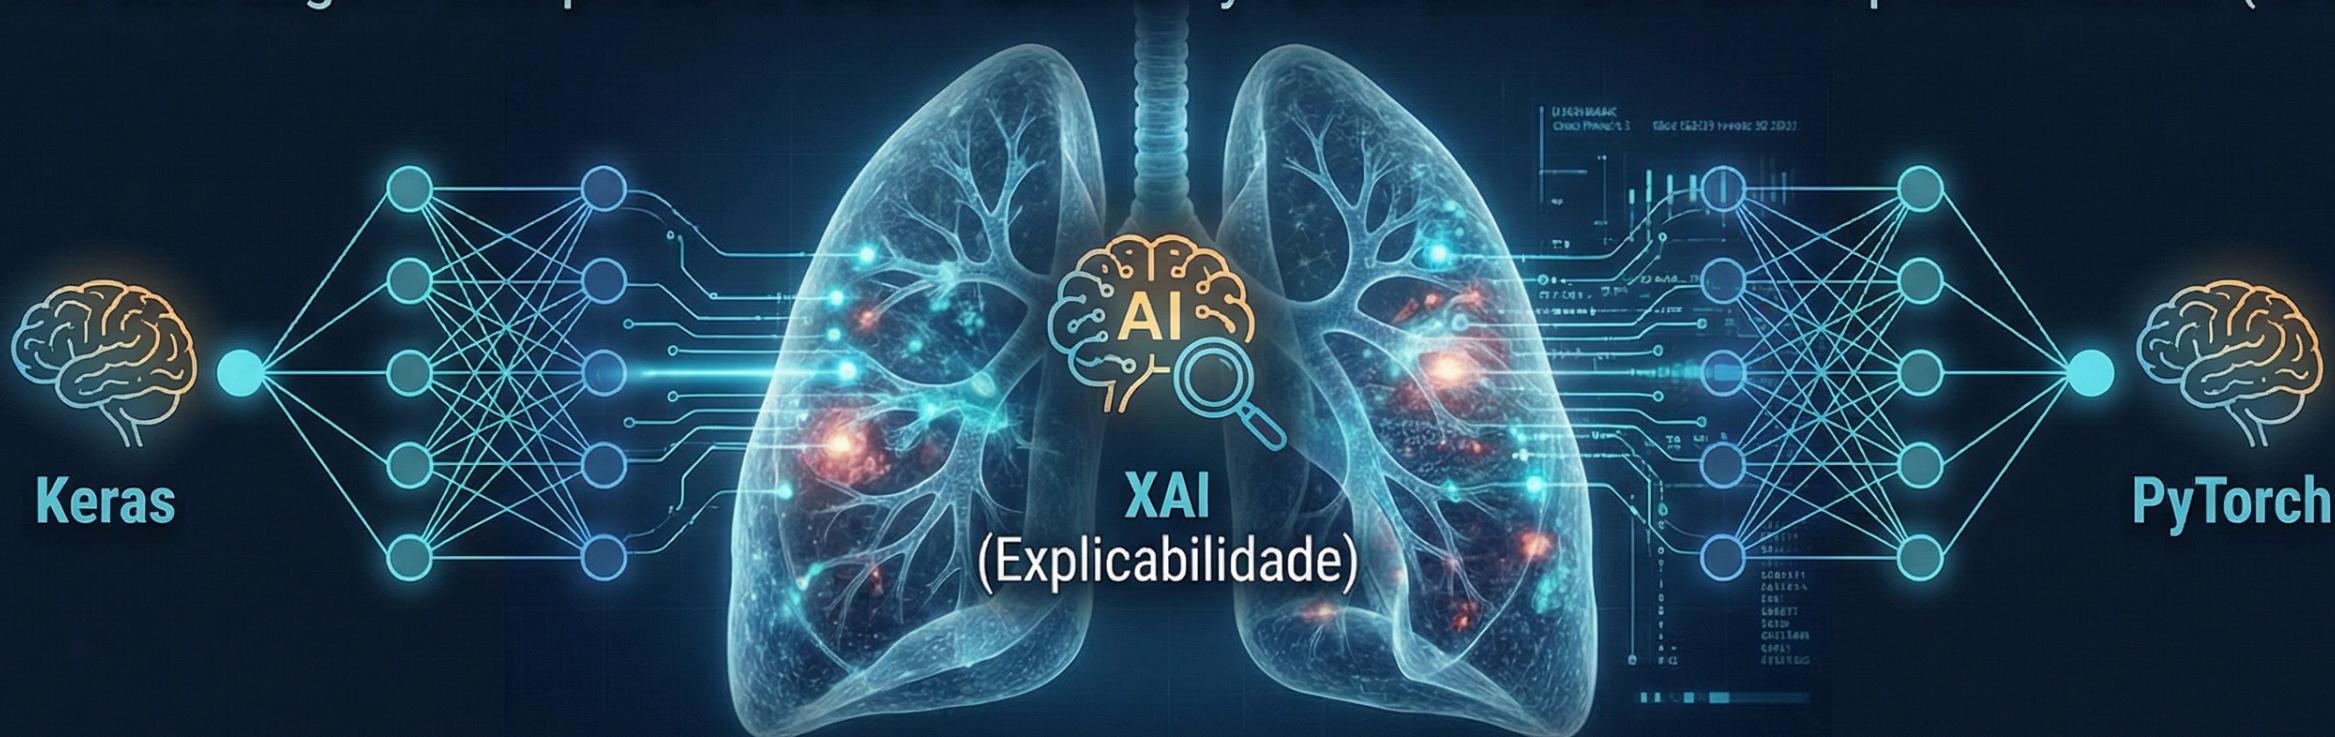


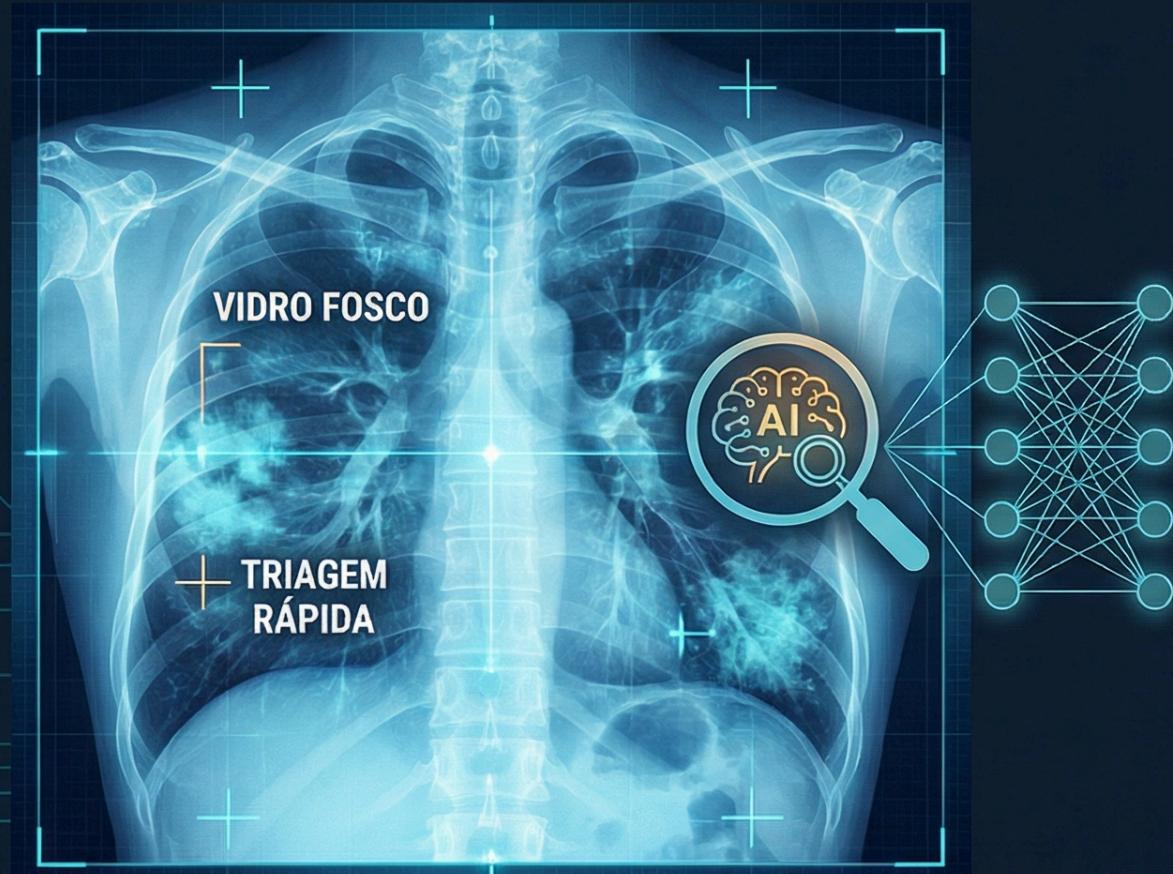
Detecção de COVID-19 em Tomografias Computadorizadas utilizando Deep Learning

Uma abordagem comparativa entre Keras e PyTorch com foco em Explicabilidade (XAI)



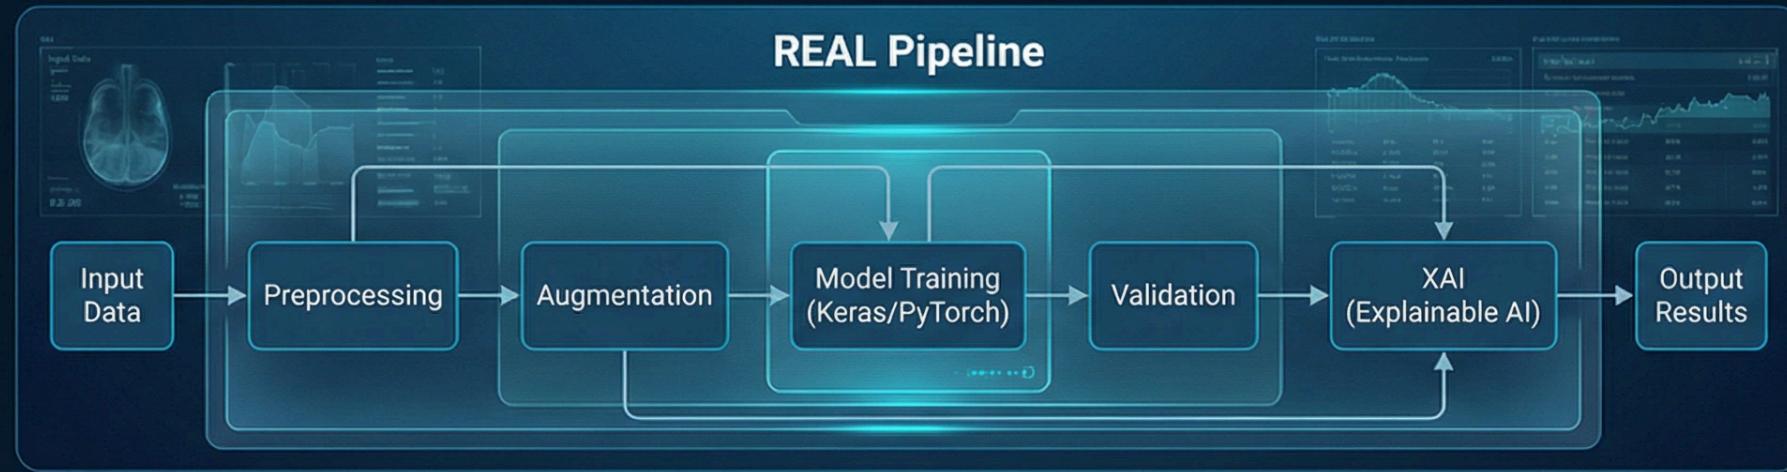
- **Abordagem Comparativa:** Keras (TensorFlow) vs. PyTorch
- **Modelos:** Redes Neurais Convolucionais (CNNs)
- **Foco em XAI:** Métodos de Interpretação (Grad-CAM, SHAP)
- **Base de Dados:** Tomografias Computadorizadas (COVID-19 Positivo/Negativo)

O Desafio Clínico: COVID-19 em Imagens Médicas



- **Diagnóstico Rápido:** A necessidade crítica de triagem eficiente durante a pandemia.
- **Limitações do RT-PCR:** Falsos negativos e tempo de espera.
- **Papel da Tomografia (CT):** Alta sensibilidade, mas dependente de radiologistas experientes.
- **Objetivo:** Automatizar a detecção de padrões visuais (vidro fosco) com IA.

Pipeline da Solução Proposta



- **Arquitetura Híbrida**

Experimentação rápida (Keras) + Controle robusto (PyTorch).

- **Engenharia de Software**

Planejamento estruturado para garantir reproduzibilidade e escalabilidade.

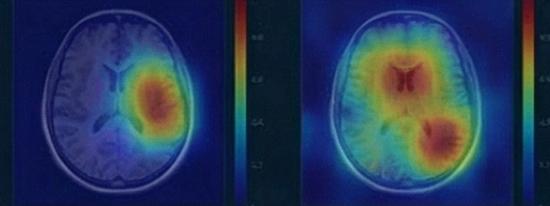
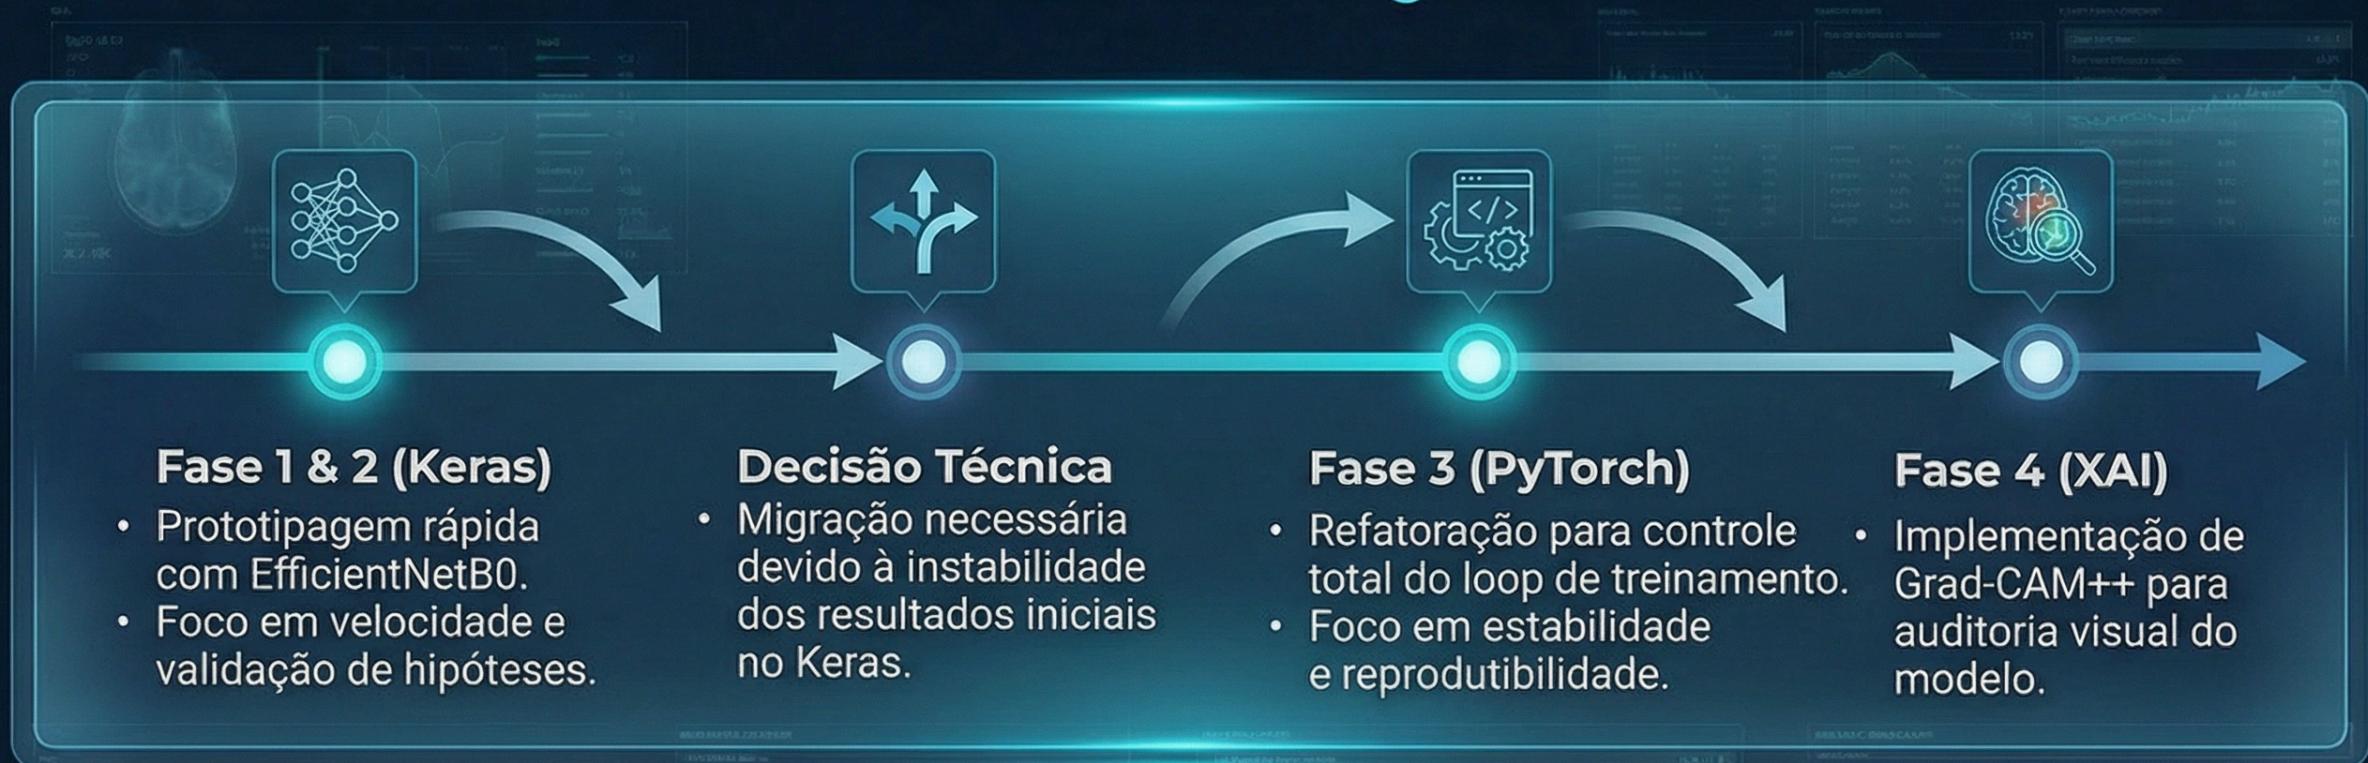
- **Fluxo de Dados**

Pré-processamento -> Augmentation -> Treinamento -> Validação -> XAI.

- **Faseamento**

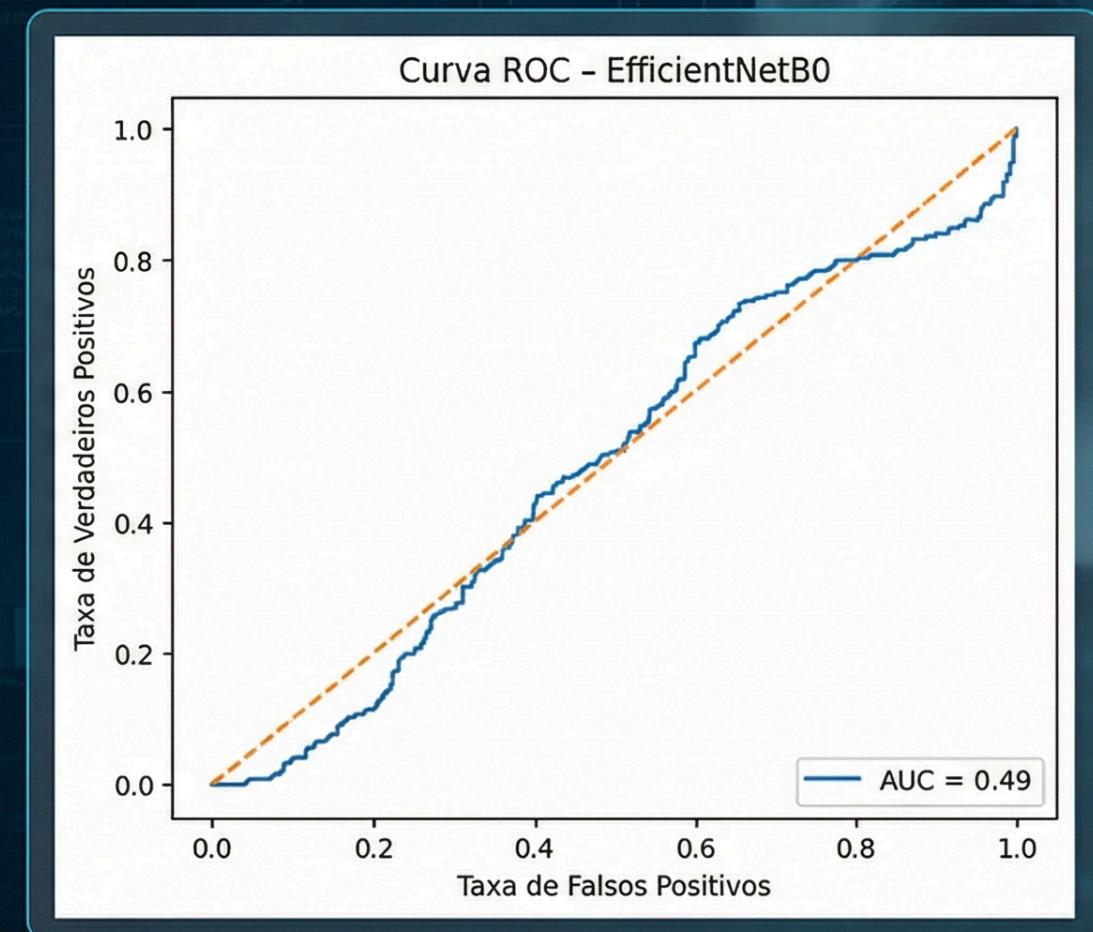
Divisão clara entre prototipagem e produto final.

Evolução Metodológica: Do Keras ao PyTorch



Fase 1 & 2: Keras/EfficientNet - Resultados e Desafios

- 🕒 **Acurácia de Pico:** Atingiu ~98% no Fold 5 (como mostrado no gráfico real).
- 📊 **Instabilidade:** Alta variabilidade entre folds e sensibilidade a hiperparâmetros.
- 📈 **Overfitting:** Risco detectado apesar da alta acurácia.
- 💰 **Limitação:** O framework Keras (na época) dificultava o controle fino do loop de treinamento.



Correções Metodológicas



Data Augmentation:
Rotação, Zoom, Flip
para aumentar a
diversidade do dataset.



Avaliação Rigorosa:
Validação Cruzada
(K-Fold) para garantir
robustez estatística.



Otimização:
Ajuste fino de Learning
Rate e Schedulers.



Regularização:
Dropout e Weight
Decay para combater
overfitting.

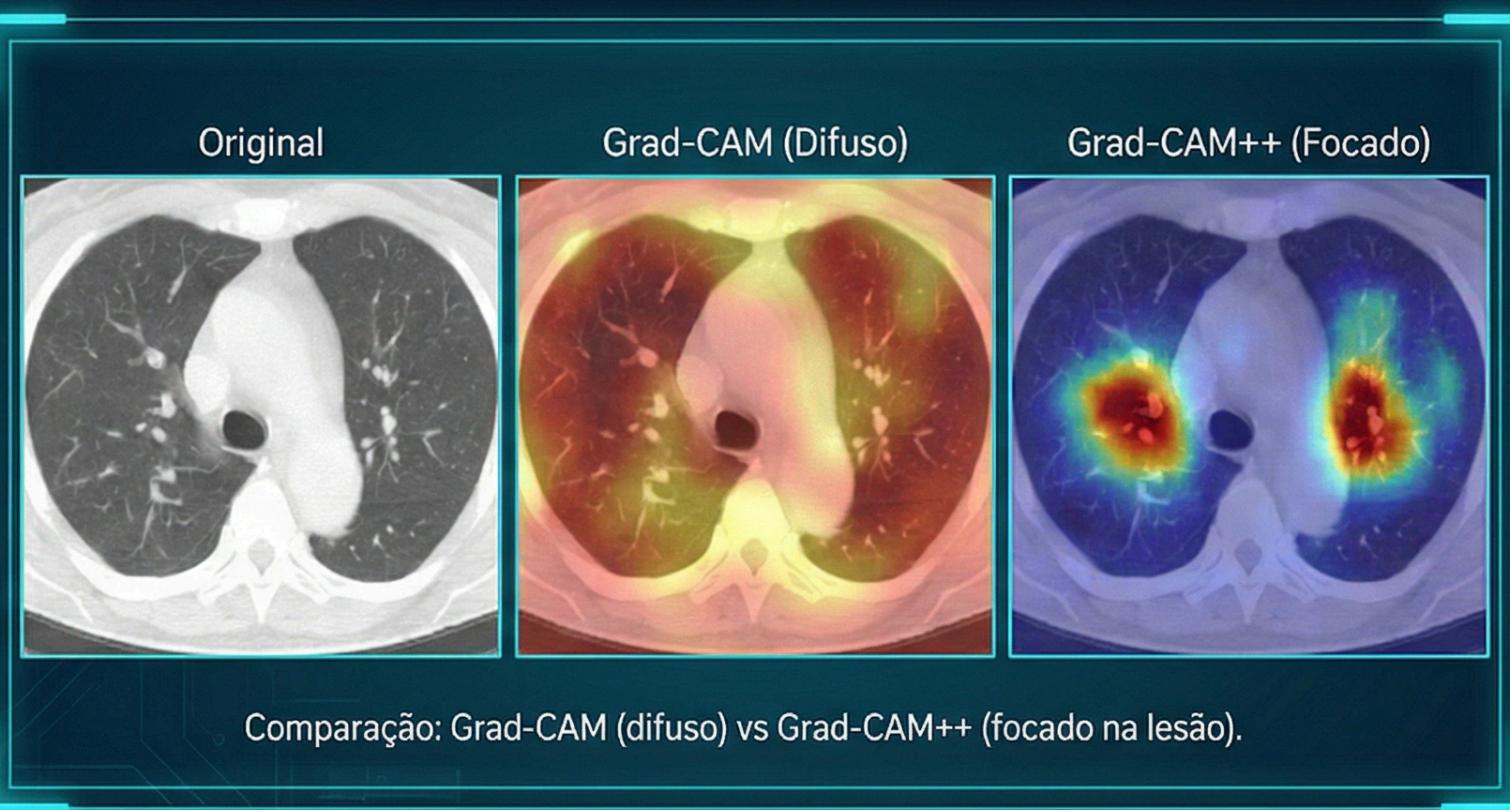
Fase 3: Robustez com PyTorch

- **Estabilidade Comprovada:** A curva de perda desce suavemente de 0.21 para 0.016.
- **Convergência:** Treinamento consistente sem oscilações bruscas.
- **Controle:** Loop de treinamento personalizado permitiu ajustes finos.
- **Resultado:** Modelo confiável para aplicação clínica.



Fase 4: Inteligência Explicável (XAI)

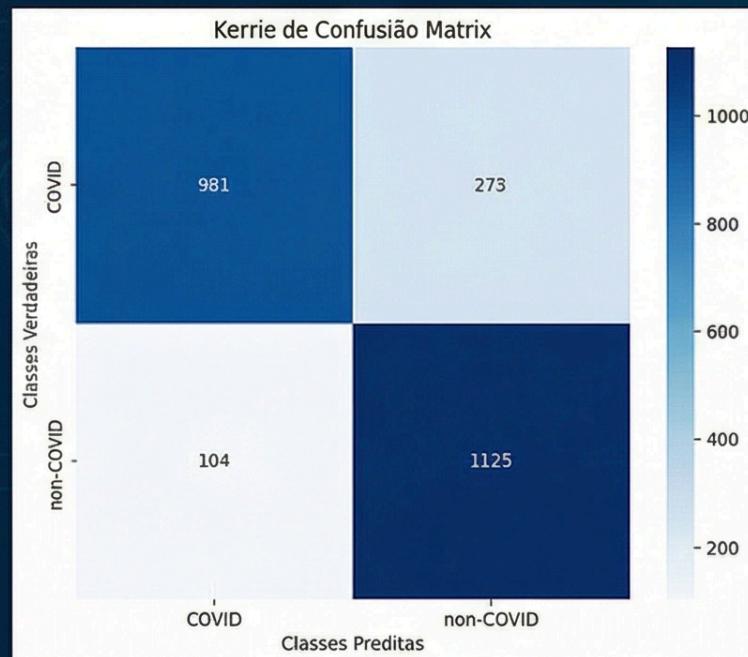
Focando na Patologia Real com Grad-CAM++



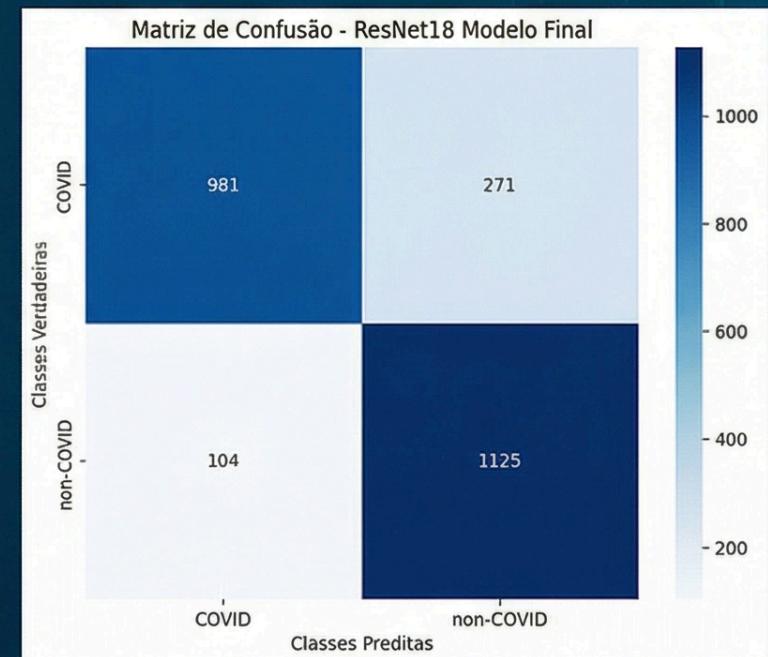
- **Comparação Visual:** Original vs Grad-CAM (difuso) vs Grad-CAM++ (focado).
- **Validação Clínica:** Grad-CAM++ ignora ossos e foca na opacidade pulmonar (vídeo fosco).
- **Confiança:** Prova de que a rede aprendeu patologias reais, não ruídos.
- **Transparência:** Essencial para aceitação médica.

Comparativo de Resultados: Keras vs PyTorch

Keras (Rápido)



PyTorch (Robusto)



- Alta acurácia, mas instável.
- Falsos negativos preocupantes.

- Estabilidade superior e redução drástica de falsos negativos.

Conclusão Visual: A matriz do PyTorch demonstra uma diagonal principal mais robusta e menos erros críticos.

O “Efeito Uau”: Grad-CAM++ em Ação



Foco Preciso: O modelo ignora costelas e tecidos saudáveis.



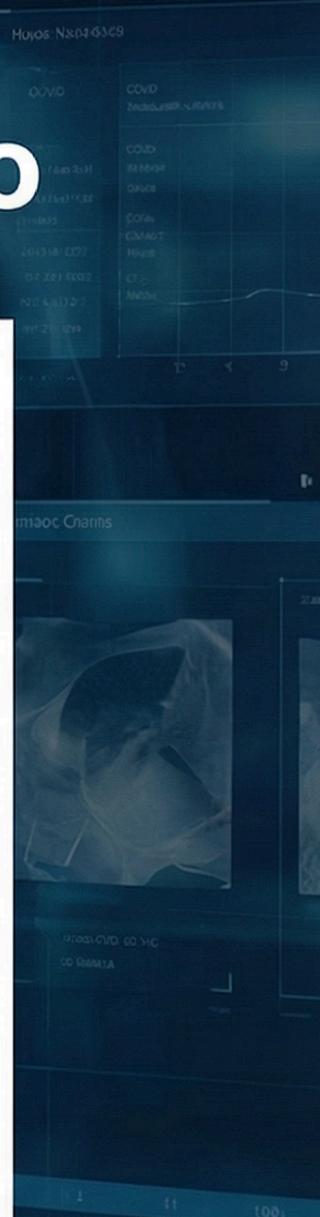
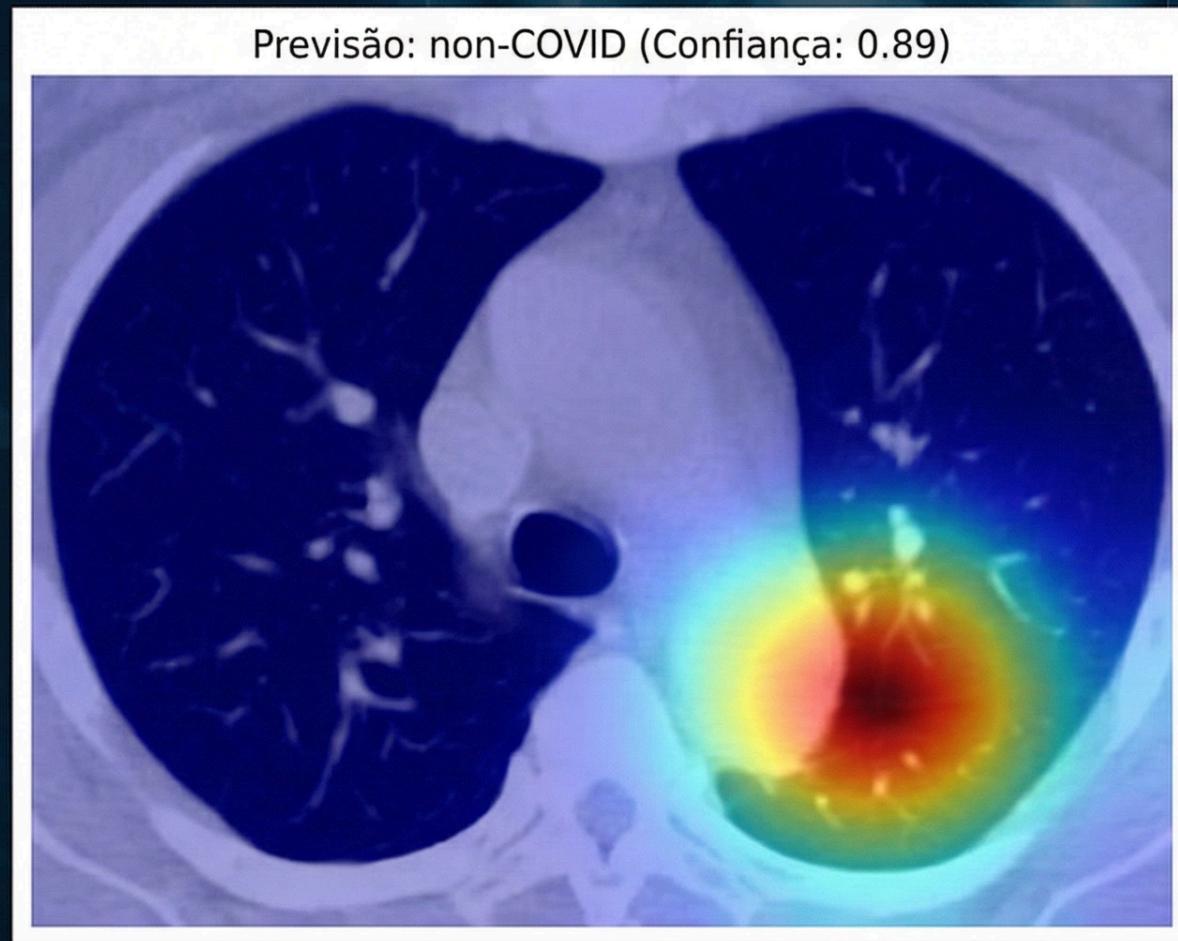
Detecção de Vidro Fosco: A área quente (vermelha) coincide perfeitamente com a lesão de COVID-19.



Validação Humana: O modelo "vê" o que o radiologista vê.



Segurança: Garantia de que a decisão não é baseada em artefatos.



Resultados Finais e Impacto



Performance: Acurácia robusta e validada em múltiplos cenários.



Confiabilidade: Baixa taxa de falsos negativos, crucial para triagem.

"Em IA para saúde, a explicabilidade não é opcional, é um requisito de segurança."

Conclusão: Por que PyTorch Venceu?



Eficiência vs Robustez: Keras foi rápido, mas PyTorch foi confiável.



A Escolha Final: Optamos pela **Confiabilidade Clínica e Explicabilidade** do PyTorch sobre a pura eficiência inicial.



Legado: Um sistema auditável é o único caminho para IA na medicina.